# Introduction aux Systèmes de Gestion de Bases de Données Relationnelles

# - Olivier Losson -

L'objectif de ce cours est l'acquisition des connaissances fondamentales relatives aux systèmes de gestion de bases de données relationnelles (SGBDr), de la conception du schéma de données à la construction du modèle relationnel et à l'exploitation des données.

La première partie présente dans ses grandes lignes la notion de SGBDr ainsi que les principes fondamentaux du modèle relationnel. La seconde partie se focalise sur la construction du modèle de données, en détaillant comment le modèle entité-association permet d'obtenir un premier schéma relationnel et comment ce dernier est normalisé pour obtenir une base cohérente. La troisième partie concerne la phase d'exploitation des données, et porte en particulier sur le langage de sélection et de manipulation de données SQL.

# - Sommaire -

I. Vers un système de gestion des données	2
I.1. Introduction	2
I.2. Objectifs et propriétés d'un SGBD	2
I.3. Composants et organisation de la mise en œuvre d'un SGBD	3
I.4. Niveaux et modèles de description des SGBD	4
I.5. Principes fondamentaux du modèle relationnel	5
II. Construire un modèle de données	6
II.1. Phases de construction	6
II.2. Le modèle entité-association	6
II.3. Passage au modèle relationnel	8
II.4. Nécessité de la normalisation dans la conception d'une BDr	9
II.5. Dépendances fonctionnelles et normalisation des relations	10
II.6. Intégrité structurelle	13
III. Exploiter les données	15
III.1. Bases de l'algèbre relationnelle	15
III.2. Le langage SQL (Structured Query Language)	17

# I. Vers un système de gestion des données

#### I.1. Introduction

### I.1.1. Quelques jalons historiques

- 1960 Uniquement des systèmes de gestion de fichiers plus ou moins sophistiqués
- 1970 Début des SGBD réseaux et hiérarchiques proches des systèmes de gestion de fichiers L'ouvrage de Codd paru en 1970, "Un modèle relationnel pour les grandes banques de données partagées", jette les bases théoriques du concept de BDr
- 1980 Les SGBDr font leur apparition sur le marché
- 1990 Les SGBDr dominent le marché et apparaissent les SGBD orientés objets (SGBDOO)

#### I.1.2. Qu'est-ce qu'une base de données?

De façon informelle, on peut considérer une *Base de Données* comme un ensemble structuré de données, centralisées ou non, servant pour les besoins d'une ou plusieurs applications, interrogeables et modifiables par un groupe d'utilisateurs en un temps opportun.

Plus formellement, une BD est un ensemble d'informations *exhaustives*, *non redondantes*, *structurées* et *persistantes*, concernant un sujet.

Une condition nécessaire pour mériter le titre de base de données est, pour un ensemble de données non indépendantes, d'être *interrogeable par le contenu* (pouvoir retrouver toutes les données qui satisfont un critère quelconque).

Un *Système de Gestion de Base de Données* peut être défini comme un ensemble de logiciels prenant en charge la structuration, le stockage, la mise à jour et la maintenance des données. Autrement dit, il permet de décrire, modifier, interroger et administrer les données. C'est, en fait, l'interface entre la base de données et les utilisateurs (qui ne sont pas forcément informaticiens).

# I.2. Objectifs et propriétés d'un SGBD

#### I.2.1. Objectifs d'un SGBD

Un SGBD doit résoudre certains problèmes et répondre à des besoins précis :

- *Indépendance physique* : la façon de définir les données doit être indépendante des structures utilisées pour leur stockage
- *Indépendance logique* : un utilisateur doit pouvoir percevoir seulement la partie des données qui l'intéresse (c'est ce que l'on appelle une *vue*) et modifier la structure de celle-ci sans remettre en cause la majorité des applications
- *Manipulation aisée* des données par des non informaticiens, ce qui suppose des langages "naturels"
- Accès efficaces aux données et obtention de résultats aux interrogations en un temps "acceptable"
- Administration centralisée des données pour faciliter l'évolution de leur structure
- *Non-redondance* : chaque donnée ne doit être présente qu'une seule fois dans la base afin d'éviter les problèmes lors des mises à jour

- **Cohérence** (ou **intégrité**): les données ne doivent présenter ni ambiguïté, ni incohérence, pour pouvoir délivrer sans erreur les informations désirées. Cela suppose un mécanisme de vérification lors de l'insertion, de la modification ou de la suppression de données
- **Partage** des données pour un accès multi-utilisateur simultané aux mêmes données. Il faut entre autre assurer un résultat d'interrogation cohérent pour un utilisateur consultant une base pendant qu'un autre la modifie
- **Sécurité** des données : robustesse vis-à-vis des pannes (il faut pouvoir retrouver une base "saine" en cas de plantage au cours de modifications) et protection par des droits contre les accès non autorisés

#### I.2.2. Propriétés d'un SGBDr

Des objectifs cités ci-dessus découlent les propriétés fondamentales d'un SGBDr :

- Base formelle reposant sur des principes parfaitement définis
- *Organisation structurée* des données dans des tables interconnectées (d'où le qualificatif *relationnelles*), pour pouvoir détecter les dépendances et redondances des informations
- Implémentation d'un *langage relationnel ensembliste* permettant à l'utilisateur de décrire aisément les interrogations et manipulation qu'il souhaite effectuer sur les données
- *Indépendance des données* vis-à-vis des programmes applicatifs (dissociation entre la partie "stockage de données" et la partie "gestion" ou "manipulation")
- Gestion des opérations concurrentes pour permettre un accès multi-utilisateur sans conflit
- Gestion de l'intégrité des données, de leur protection contre les pannes et les accès illicites

#### I.3. Composants et organisation de la mise en œuvre d'un SGBD

#### I.3.1. Composants des SGBD

Un SGBD va donc posséder un certain nombre de composants logiciels chargés de :

- *la description des données* au moyen d'un *Langage de Définition de Données* (LDD). Le résultat de la compilation est un ensemble de tables, stockées dans un fichier spécial appelé dictionnaire (ou répertoire) des données
- la manipulation des données au moyen d'un Langage de Manipulation de Données (LMD) prenant en charge leur consultation et leur modification de façon optimisée, ainsi que les aspects de sécurité
- *la sauvegarde et la récupération après pannes*, ainsi que des mécanismes permettant de pouvoir revenir à l'état antérieur de la base tant qu'une modification n'est pas finie (notion de *transaction*)
- *les accès concurrents aux données* en minimisant l'attente des utilisateurs et en garantissant l'obtention de données cohérentes en cas de mises à jours simultanées

Une *architecture Client-Serveur* met en œuvre un ou plusieurs ordinateurs (Clients), qui exécutent un programme applicatif, communiquant avec un ordinateur distant (Serveur) qui traite leurs requêtes. Dans ce modèle, la communication des requêtes et des résultats entre le programme applicatif du client et le SGBDr, qui se trouve sur le serveur, est assurée par une couche logicielle médiatrice (Middleware).

### I.3.2. Organisation de la mise en œuvre des BD

Les données constituent aujourd'hui une ressource vitale et stratégique pour l'entreprise. Les besoins concernent autant les données propres que celles de l'extérieur, avec pour objectif de sécuriser, maintenir et mettre à jour ces informations. Quatre catégories de fonctions sont impliquées dans cette gestion de données :

- les tâches liées à l'*architecture de données* consistent à analyser, classifier et structurer les données au moyen de modèles confirmés
- l'administration de données vise à superviser l'adéquation des définitions et des formats de données avec les directives de standardisation et les normes internationales, à conseiller les développeurs et les utilisateurs, et à s'assurer de la disponibilité des données à l'ensemble des applications. L'administrateur assume en outre des responsabilités importantes dans la maintenance et la gestion des autorisations d'accès
- les professionnels en *technologie de données* ont en charge l'installation, la supervision, la réorganisation, la restauration et la protection des bases. Ils en assurent aussi l'évolution au fur et à mesure des progrès technologiques dans ce domaine.
- l'*exploitation de données* consiste à mettre à disposition des utilisateurs les fonctions de requête et de reporting (générateurs d'*états*), ainsi qu'à assurer une assistance aux différents services pour qu'ils puissent gérer leur stock propre de données en autonomie (service *infocentre*).

# I.4. Niveaux et modèles de description des SGBD

# I.4.1. Niveaux de description

Trois niveaux de description (ou d'abstraction) des données sont définis (norme ANSI/SPARC) :

- *Niveau interne* (ou *physique*) : concerne le stockage des données au niveau des unités de stockage, des fichiers; c'est ce que l'on appelle le *schéma interne*
- *Niveau conceptuel* (ou *logique*) : décrit la *structure* des données dans la base, leurs propriétés et leurs relations, indépendamment de toute préoccupation technologique d'implémentation ou d'accès par les utilisateurs; c'est ce que l'on appelle le *schéma conceptuel*
- *Niveau externe* : décrit comment chaque utilisateur perçoit les données; c'est ce que l'on appelle le *schéma externe* ou *vue*.

#### I.4.2. Modèles de description

Le résultat de la conception d'une base de données est une description des données (appelée *schéma*) en termes de propriétés d'ensembles d'objets et d'organisation logique des données. Pour obtenir une telle représentation à partir d'un problème réel, on utilise un outil appelé *modèle de description*, basé sur un ensemble de concepts et de règles formant le langage de description. Un SGBD peut être caractérisé par le modèle de description qu'il supporte. Une fois la base de données ainsi spécifiée, il est possible de manipuler les données en réalisant des opérations de sélection, d'insertion, de modification et de suppression, et ce au moyen d'un langage spécifique de manipulation de données, mais aussi par des langages de programmation "classiques". Plusieurs types de modèles sont utilisés :

- *modèles réseau* et *hiérarchique*: une base de données est vue comme un ensemble de fichiers reliés par des pointeurs (ces modèles privilégiant l'optimisation des entrées-sorties, ils sont nommés *modèles d'accès*) et les données y sont organisées en réseau et en arbre (respectivement). Un nœud quelconque peut avoir plusieurs pères dans le modèle réseau, un seul dans le modèle hiérarchique
- *modèle relationnel*: les données et les relations qui les unissent sont organisés sous forme de lignes regroupées au sein de tables. Chaque table est composée d'une ou plusieurs colonnes, dont certaines servent à caractériser chaque ligne de manière unique (notion de *clé*, voir section I.5 ci-dessous)
- *modèle objet* : nés dans le prolongement de la programmation orientée objets (POO), les SGBDOO permettent de représenter et de manipuler des objets complexes. Leur avantage est la réduction des coûts de développement et de maintenance, ainsi qu'une performance accrue, puisque la base

"connaît" la structure objet du programme (relations d'héritage, pointeurs entre objets, etc.). On distingue :

- les systèmes d'encapsulation d'objets, surcouches logicielles de bases relationnelles intégrant le code d'interfaçage pour le stockage d'objets. Ces systèmes permettent de bénéficier des gains de productivité des bases objets, mais non des performances
- *les bases objets* proprement dites sont totalement fondées sur le modèle objet. Elles ne nécessitent plus de langage spécifique de manipulation de données (comme SQL), car la base utilise directement un langage objet (comme C++, Smalltalk ou Eiffel), en implémentant une extension propre aux mécanismes des BD (verrouillage, transactions, intégrité référentielle, ...).

# I.5. Principes fondamentaux du modèle relationnel

# I.5.1. Table (ou Relation) et Attribut

Une table (ou relation) est un tableau à deux dimensions dans lequel chaque colonne (appelée *attribut*) porte un nom différent et où les données figurent en ligne. Aussi bien pour les colonnes que pour les lignes, une table peut en contenir un nombre quelconque et leur ordre est indifférent. On trouve encore les vocables d'*enregistrement*, *n-uplet* ou *tuple* pour désigner une ligne et de *champ* pour une colonne; un enregistrement est donc un ensemble de valeurs, chacune renseignant un champ.

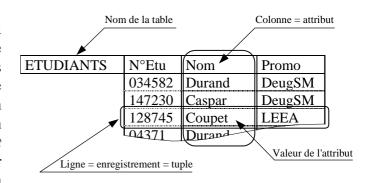


Figure 1 : Exemple de relation

#### I.5.2. Clé

Dans la table de l'exemple ci-dessus, le numéro d'étudiant est un attribut constitué d'un code artificiel. Cet attribut particulier, appelé *clé*, est indispensable pour pouvoir identifier chaque étudiant de manière unique, car aucun autre attribut ni aucune combinaison d'attributs n'auraient pu garantir cela. En effet, l'attribut *nom* peut prendre plusieurs fois la même valeur et n'est donc pas un bon candidat pour être une clé de la table; de même, si l'on avait disposé du prénom des étudiants, la composition d'attributs *<nom,prénom>* n'aurait pas été davantage satisfaisante comme clé, car il est possible que 2 étudiants portent à la fois le même nom et le même prénom.

Une *clé d'identification* ou *clé* d'une table est un attribut ou une combinaison d'attributs qui satisfait :

- une contrainte d'*unicité* : chaque valeur clé désigne de manière unique une ligne de la table ; autrement dit, deux lignes ne peuvent posséder des valeurs identiques pour le(s) attribut(s) de la clé
- une contrainte de *minimalité* : si une clé est composée d'un ensemble d'attributs, cette combinaison doit être minimale (aucun attribut ne peut en être retiré sans violer la règle d'unicité).

S'il y a plusieurs clés envisageables pour une même table, on choisit parmi celles-ci une *clé primaire*.

### II. Construire un modèle de données

#### II.1. Phases de construction

Un *modèle de données* est une description formelle et structurée des données et de leurs liens de dépendance dans un système d'information. Pour aboutir à une base de données relationnelle décrivant le monde réel, il faut procéder en trois étapes :

- analyse des données. A partir d'une réalité perçue, il s'agit de spécifier les données nécessaires pour en construire un système d'information représentatif. Les utilisateurs participent activement à cette phase en exprimant leurs besoins dans leur langage. Le résultat de ces consultations est une documentation aussi complète que possible, comportant une description explicite des objectifs recherchés, ainsi qu'une spécification textuelle des données et de leurs interdépendances.
- élaboration d'un modèle entité-association. Partant de l'analyse des données réalisée, on identifie les objets concrets ou abstraits à propos desquels on veut conserver des informations, ainsi que les liens entre ceux-ci. Dans ce modèle, un objet est appelé entité et un lien, association; les ensembles d'entités et d'associations sont, respectivement, représentés graphiquement par des rectangles et par des losanges. Le modèle entité-association fournit des outils et un cadre rigoureux pour l'analyse des données et de leurs liaisons.
- conversion du modèle entité-association en un *modèle relationnel*. Il s'agit de transformer en tables toutes les entités et les associations du modèle précédent. Chaque liaison est convertie en une table contenant les clés des ensembles d'entités y participant (appelées *clés étrangères*), en plus d'éventuels attributs de la liaison.

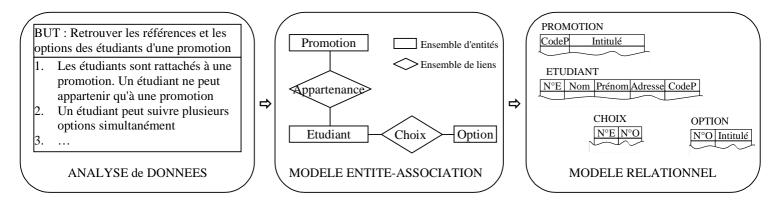


Figure 2 : Phases de construction d'une base de données relationnelle

Une fois ainsi obtenu un *schéma de base de données relationnelle*, il faut détecter et étudier les dépendances au sein des tables pour en éliminer les informations redondantes et les anomalies qui en résultent. Les concepts de *dépendance fonctionnelle*, de *forme normale* et d'*intégrité référentielle*, permettent de réaliser ces objectifs.

# II.2. Le modèle entité-association

#### II.2.1 Définitions

- Une *entité* est un objet spécifique, concret ou abstrait, de la réalité perçue. Ce peut être une personne, un objet inerte, un concept abstrait, un événement, ...

- Un *attribut* est une caractéristique ou une qualité d'une entité ou d'une association. Il peut être atomique (ex. nom, prénom) ou composé (ex. adresse=n°+rue+code\_postal+ville) et peut prendre une ou plusieurs valeur(s) (on parle d'attribut *mono* ou *multivalué*). Le *domaine* d'un attribut est l'ensemble des valeurs que peut prendre celui-ci; il est utile pour vérifier la validité d'une donnée.
- Un *type d'entité* est la classe de toutes les entités de la réalité perçue qui sont de même nature et qui jouent le même rôle. Un type d'entité est défini par un *nom* et un ensemble d'*attributs*, qui sont les caractéristiques communes à toutes les entités de même type; ces dernières forment un *ensemble d'entités* (par exemple, un ensemble d'étudiants, caractérisés par leurs nom et prénom). Par simplification de la terminologie, on appellera *entité* un type d'entité, et *occurrence d'une entité* un individu particulier faisant partie d'une entité.
- Le *schéma* ou *intention* d'une entité en est la description ; l'ensemble des occurrences d'une entité qui existent dans la base à un instant donné s'appelle l'*extension* de l'entité. Le schéma d'une entité ne change pas fréquemment car il en décrit la structure ; son extension, en revanche, change à chaque insertion ou suppression d'une occurrence d'entité.
- L'attribut *clé* ou *identifiant* d'une entité est un groupe minimal d'attributs permettant de distinguer sans ambiguïté les occurrences d'entités dans l'ensemble considéré.
- Une association est une correspondance entre 2 ou plusieurs occurrences d'entités à propos de laquelle on veut conserver des informations. On dit que les occurrences d'entités *participent* ou jouent un *rôle* dans l'association. Un *type d'association* est défini par un *nom* et une liste d'entités avec leur rôle respectif (notation : A(ro<sub>1</sub>:E<sub>1</sub>, ro<sub>2</sub>:E<sub>2</sub>,..., ro<sub>n</sub>:E<sub>n</sub>)). Pour simplifier, on appelle *association* un type d'association et *occurrence d'association* toute correspondance qui existe entre 2 ou plusieurs occurrences d'entités. L'ensemble des occurrences d'une association qui existe dans la base à un instant donné s'appelle l'*extension* de l'association.

Exemple d'association : APPARTENANCE(appartient: ETUDIANT, inclut: PROMOTION) décrit le fait qu'un étudiant appartient à une promotion et, symétriquement, qu'une promotion inclut plusieurs étudiants (cf. figure 3)

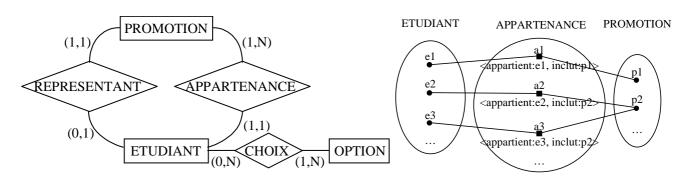


Figure 3-1 : Exemple de modèle entité-association

Figure 3-2 : Exemples d'occurrences de l'association APPARTENANCE

- Une association peut aussi posséder des attributs. Un attribut de l'association APPARTENANCE pourrait être, par ex., un entier indiquant le(s) semestre(s) universitaire(s) suivi(s) par l'étudiant.
- Le *degré* (ou la *dimension*) d'une association est le nombre d'entités y participant. Le cas le plus fréquent est celui de l'association binaire

#### II.2.2. Cardinalité d'une association

La *cardinalité* d'une association spécifie le nombre minimum et le nombre maximum de participations de chaque occurrence d'entité à chaque rôle de l'association. Autrement dit, la cardinalité de A(ro<sub>1</sub>:E<sub>1</sub>,

 $ro_2:E_2,...,ro_n:E_n$ ) est définie par un ensemble de couples  $(min_i, max_i)$  où  $min_i$   $(resp. max_i)$  indique le nombre minimum (resp. maximum) de fois que toute occurrence de  $E_i$  doit assumer le rôle  $ro_i$ . On distingue 4 cas principaux :

Type	Cardinalité	Exemple (cf. figure 3)	
Simple (1,1) (ou <i>de type 1</i> )		Chaque étudiant est inscrit dans une et une seule promotion	
Simple	(0,1) (ou conditionnelle)	Chaque étudiant n'est pas forcément représentant de sa promo	
Complexe	(1,N) (ou <i>multiple</i> )	Chaque promotion comporte plusieurs étudiants	
Complexe	(0,N) (ou multiple conditionnelle)	Chaque étudiant choisit un nombre quelconque d'options	

La section suivante décrit des règles permettant d'obtenir un modèle relationnel à partir du modèle entité-association. Ce dernier occupe une place importante dans la modélisation de données assistée par ordinateur, mais le processus de traduction en un modèle relationnel n'est que partiellement automatisé, même dans les ateliers de génie logiciel CASE (Computer-Aided Software Ingeneering).

# II.3. Passage au modèle relationnel

### II.3.1. Notion de clé étrangère

Une *clé étrangère* d'une relation R est un sous-ensemble C des attributs de R tel que :

- il existe une relation R' (pas nécessairement distincte de R) possédant une clé candidate C';
- pour chaque valeur différente de C dans R, il existe une valeur (unique) de C' dans R' identique à C.

Autrement dit, une clé étrangère dans une table est un attribut ou une concaténation d'attributs qui forme une clé d'identification d'une autre table (ou éventuellement de la même table). La clé primaire d'une table comportant des clés étrangères peut être soit une concaténation de celles-ci, soit une autre clé candidate - par exemple une clé créée artificiellement.

### II.3.2. Règles de passage

L'opération consiste à représenter sous forme de tables les entités et les associations obtenues précédemment. Pour cela, on applique les règles suivantes :

- Chaque entité est traduite en une table distincte, dont la clé primaire peut être soit celle de l'entité, soit une autre clé candidate. Les autres attributs de l'entité sont reportés comme attributs de la nouvelle table.
- La conversion d'une association dépend de sa cardinalité :
  - R1. Une association de dimension 2 de type simple-complexe (par exemple, (1,1)-(1,N)) ne nécessite pas la création d'une nouvelle table, mais est traduite en définissant une clé étrangère dans la table qui se situe du côté "simple" de l'association. Cette clé doit faire référence à la clé d'identification de la seconde table, et son nom est judicieusement choisi en conséquence.
  - R2. Une association de dimension 2 de type simple-simple (par exemple, (1,1)-(0,1)) se traite de la même façon, en choisissant en principe d'introduire la clé étrangère dans la table située du côté (1,1) de l'association.
  - R3. Chaque association de dimension 2 de type complexe-complexe (par exemple, (0,N)-(1,N)) est représentée par une table distincte, contenant les identifiants des deux entités associées comme clés étrangères. Ces attributs constituent souvent, à eux deux, la clé primaire de la nouvelle table. Si l'association comporte d'autres attributs, ceux-ci sont également ajoutés à la table.
  - R4. Une association de dimension supérieure à 2 se réécrit selon la règle R3.

### II.3.3. Exemples

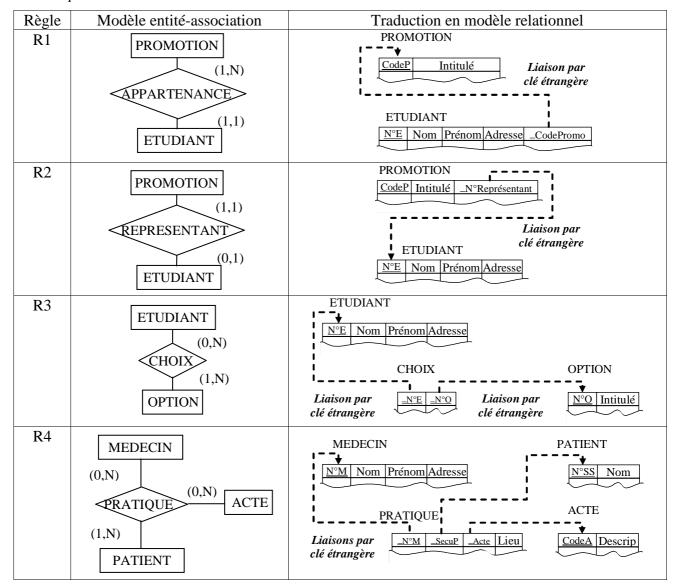
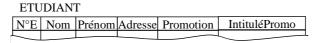


Figure 4 : Ex. d'applications des règles de passage modèle entité-association ⇒ modèle relationnel

# II.4. Nécessité de la normalisation dans la conception d'une BDr

#### II.4.1. Redondance d'un attribut

Supposons que le modèle relationnel obtenu pour représenter les données relatives à l'inscription des étudiants dans une promotion se soit réduit à une seule table (suite à une mauvaise conception du modèle entité-association) :



Une telle conception entraîne des problèmes de *redondance* des informations. On s'aperçoit en effet que l'intitulé de la promotion est répété pour chaque étudiant, et qu'il est identique pour tous les étudiants inscrits dans la même promotion. Cet attribut est donc redondant, et il est préférable de stocker ces informations, relatives à une promotion, dans une table séparée.

#### II.4.2. Anomalies de mutation

En outre, le schéma précédent n'est pas satisfaisant car il engendre certaines anomalies lors des opérations de mise à jour, d'insertion et de suppression des données (anomalies dites *de mutation*).

- Si par exemple on modifie l'intitulé d'une promotion dans un tuple (ex. de "Sciences de la Vie" en "Sciences du Vivant"), ce même intitulé devra être changé pour tous les autres étudiants concernés, sans quoi cette promotion possédera plusieurs intitulés différents (*anomalie de mise à jour*).
- Si une nouvelle promotion se crée, elle ne pourra pas être ajoutée dans la table sans y inscrire immédiatement des étudiants, car la clé primaire (N°E) ne peut être laissée vide. Cette *anomalie d'insertion* peut être gênante, par exemple, parce que le stockage d'informations sur la nouvelle formation (maquette, intervenants, ...) doit pouvoir intervenir avant toute inscription d'étudiant.
- Si l'on supprime tous les étudiants de la table (par exemple parce qu'ils ont tous eu leur diplôme !), on perd du même coup toutes les informations relatives aux promotions (*anomalie de suppression*).

Une base de données relationnelle doit stocker un ensemble de schémas relationnels sans redondance inutile et sans comportement anormal des relations lors des opérations de mise à jour. C'est pourquoi la théorie de la normalisation des relations a été associée au modèle relationnel.

# II.5. Dépendances fonctionnelles et normalisation des relations

#### II.5.1. Dépendance fonctionnelle : définitions

Introduite par Codd en 1970, la notion de dépendance fonctionnelle (DF) permet de caractériser des relations qui peuvent être décomposée sans perte d'information. Sa formalisation mathématique découle de l'observation des rôles de cardinalité simple (au plus égale à 1). Intuitivement, une DF traduit le fait que les valeurs de certains attributs sont nécessairement déterminées (fixées) lorsque le sont celles d'autres attributs.

On dit qu'un attribut ou un ensemble d'attributs Y est *fonctionnellement dépendant* d'un autre (ensemble d') attribut(s) X si, à chaque valeur prise par X correspond une valeur unique de Y. Autrement dit, des valeurs identiques de X impliquent des valeurs identiques de Y. Cette dépendance est notée  $X \rightarrow Y$ .

Une propriété remarquable des clés d'identification est que, justement, tout attribut non-clé dépend fonctionnellement de la clé, puisque celle-ci identifie chaque tuple de manière unique.

Une des propriétés de la DF est la transitivité :  $X \rightarrow Y$  et  $Y \rightarrow Z \Rightarrow X \rightarrow Z$ . On dit qu'un attribut Z est *transitivement dépendant* d'un attribut X s'il existe un attribut Y tel que  $X \rightarrow Y$  et  $Y \rightarrow Z$ , **et** aussi que X ne dépend pas fonctionnellement de Y.

#### II.5.2. Normalisation des relations

Afin d'éliminer les divers types de dépendances, et donc éviter les anomalies de mutation, on applique un processus de normalisation sur les différentes relations de la base. Les étapes successives de ce processus imposent des critères de plus en plus restrictifs aux tables normalisées :

- Une relation est en *première forme normale* (notée 1NF) si les domaines de tous ses attributs sont des valeurs atomiques (et non des ensembles, types énumérés ou listes). Tout attribut d'une relation 1NF doit donc être monovalué.

# La 1NF permet d'éliminer les domaines composés.

Pour normaliser une table à la 1NF, il suffit de créer un tuple distinct pour chaque valeur de l'attribut multivalué. Cela introduit des redondances, mais la deuxième forme normale permet d'y remédier.

- Une relation est en deuxième forme normale (2NF) si elle est 1NF et si, de plus, tout attribut non-clé dépend fonctionnellement de **toute** la clé (et pas seulement d'une partie de celle-ci). Pour qu'une table soit 2NF, il faut donc, si sa clé est *composée* (sous-entendu, de plusieurs attributs), que tout autre attribut soit fonctionnellement dépendant de la clé entière (on dit parfois qu'il y a *dépendance fonctionnelle totale*).

# La 2NF garantit qu'aucun attribut n'est déterminé seulement par une partie de la clé

Pour normaliser à la 2NF une table possédant une clé composée, il faut décomposer celle-ci en :

- une table formée des attributs dépendants d'une partie de la clé, et de cette partie même.
- une seconde table formée de la clé composée et des attributs restants :

- Une relation est en troisième forme normale (3NF) si elle est 2NF et si, de plus, tout attribut non-clé ne dépend pas transitivement de la clé (ou, autrement dit, si tout attribut non-clé ne dépend pas fonctionnellement d'un attribut non-clé).

### La 3NF permet d'éliminer les redondances dues aux dépendances transitives.

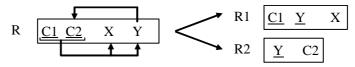
Pour normaliser à la 3NF une table possédant une dépendance transitive, il faut décomposer celle-ci en :

- une table formée de l'attribut redondant et de l'attribut dont il dépend (nommé ici X); ce dernier devient la clé de la nouvelle table
- une seconde table formée de la clé, de l'attribut X comme clé étrangère, et des autres attributs :

Les formes normales 2NF et 3NF assurent l'élimination des redondances parmi les attributs non-clé, mais pas les redondances potentielles au sein d'attributs formant une clé composite. C'est pourquoi Boyce et Codd ont proposé une extension de la 3NF.

- Une relation est en forme normale de Boyce-Codd (BCNF) si, et seulement si, les seules dépendances fonctionnelles élémentaires<sup>1</sup> sont celles dans lesquelles une clé détermine un attribut non-clé.

Plus simple que la 3NF, un peu plus restrictive, cette forme est utile lorsqu'une table possède plusieurs clés candidates. Plus précisément, lorsque les clés se chevauchent dans une table, celle-ci risque de transgresser la forme normale de Boyce-Codd, même si elle est en 3NF. Il faut alors la décomposer d'après les clés candidates :



Toute relation admet au moins une décomposition en BCNF qui est sans perte ; cependant, une telle décomposition ne préserve généralement pas les dépendances fonctionnelles.

<sup>&</sup>lt;sup>1</sup> Une *dépendance fonctionnelle élémentaire* est de la forme X→A, où A est un attribut unique n'appartenant pas à X et où il n'existe pas X' inclus dans X tel que X'→A.

#### Remarque:

Il existe deux autres formes normales, encore plus restrictives, mais qui se rencontrent bien moins fréquemment. La quatrième (4NF), par exemple, est basée sur les dépendances multivaluées<sup>1</sup>.

# II.5.3. Exemple

Dans la pratique, les critères des formes normales sont satisfaits si le modèle entité-association est bien construit et si les règles de passage au modèle relationnel ont été correctement appliquées. La vérification de toutes les formes normales successives n'a plus alors besoin d'être systématique.

Supposons au contraire que le modèle entité-association ait fourni la relation suivante (figure 5-1). A l'évidence, celle-ci n'est pas en 1NF; il faut donc la transformer conformément à la figure 5-2. La clé de la nouvelle table, composée des attributs  $N^{\circ}E$  et *Option*, détermine bien de manière unique les attributs qu'on dépendances fonctionnelles non-clé (c'est-à-dire a les  $(N^{\circ}E, Option) \rightarrow Nom$ , (N°E,Option)→Prénom, et (N°E,Option)→Adresse). Cependant, la transformation a manifestement créé des redondances et, intuitivement, on sait que l'adresse de l'étudiant n'a aucun rapport avec l'option choisie. Cela se traduit par le fait que les attributs non-clé sont fonctionnellement dépendants d'une partie de la clé (N°E→Nom, N°E→Prénom, et N°E→Adresse). La deuxième forme normale exige donc de créer deux tables séparées (figure 5-3).

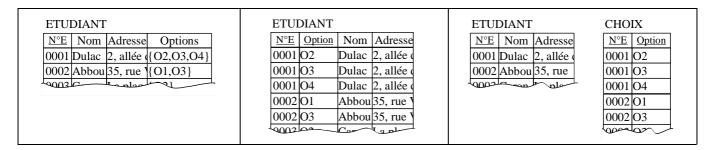
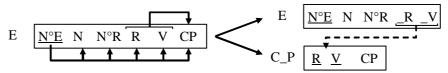


Fig. 5-1: Forme non normalisée

Figure 5-2: Forme 1NF

Figure 5-3: Forme 2NF

Supposons qu'en plus des attributs précédents, on ait stocké dans la table ETUDIANT le code postal et la ville, et qu'on ait séparé le numéro de voie et la rue. La 2NF correspondante est représentée figure 6-1 (la table CHOIX n'a pas été représentée). Dans cette table, l'attribut *CodePostal* dépend fonctionnellement de l'attribut composé (Rue,Ville)² et, par là même, dépend transitivement de la clé. Pour passer en 3NF, il faut donc créer une table CODE\_POSTAL distincte, et faire apparaître dans ETUDIANT l'attribut codant la rue et la ville sous forme de clé étrangère (figure 6-2) :

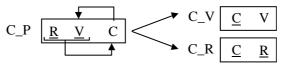


Dans la nouvelle table, on s'aperçoit toutefois qu'il y a encore de la redondance. En effet, si la clé composée de la rue et de la ville détermine bien le code postal, la ville est aussi fonctionnellement

<sup>&</sup>lt;sup>1</sup> On dit qu'il existe une *dépendance multivaluée* d'un attribut X vers un attribut Z (notée  $X \rightarrow Z$ ) si toute combinaison d'une valeur donnée de X avec celle d'un autre attribut Y détermine un ensemble identique de Z.

<sup>&</sup>lt;sup>2</sup> Il faut entendre "Ville" ici au sens de "Bureau distributeur". S'il peut en effet y avoir plusieurs codes postaux pour un même bureau distributeur (ex. 59000 et 59800 pour Lille), un bureau distributeur peut regrouper plusieurs petites "villes" rurales. On a supposé de surcroît que (Rue,Ville)→CodePostal, c'est-à-dire que la connaissance d'un nom de rue et de la ville détermine sans ambiguïté le code postal. En conséquence, l'attribut composé (Rue,Ville) est choisi comme clé, ce qui implique qu'il n'y a qu'une seule rue portant un nom donné dans une ville donnée, même pour des secteurs de codes postaux différents.

dépendante du code postal (c'est-à-dire (Rue,Ville)→CodePostal et CodePostal→Ville). Ceci est lié au fait que l'attribut (Rue, CodePostal) constitue également une clé candidate (*clé secondaire*). Pour obtenir une forme normale de Boyce-Codd, il faut donc décomposer cette relation en deux (figure 6-3) :



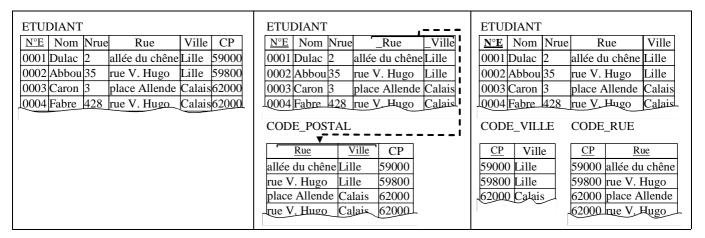


Figure 6-1: Forme 2NF

Figure 6-2: Forme 3NF

Figure 6-3: Forme BCNF

# II.6. Intégrité structurelle

### II.6.1. Définition et typologie

Une *contrainte d'intégrité* (CI) est une propriété ou une règle que doivent satisfaire les données de la base pour être considérées comme correctes (sans ambiguïtés ni incohérences). Une base de données est dite *intègre* ou *cohérente* si ses contraintes d'intégrité sont satisfaites. En pratique, ces contraintes ont pour effet de limiter les occurrences possibles des structures d'informations. La conception d'une base de données relationnelle se compose du schéma relationnel même et d'un ensemble de CIs.

De façon générale, on distingue :

- les contraintes d'intégrité statiques sont des propriétés qui doivent être vérifiées à tout moment :
  - les contraintes *individuelles* imposent un type de donnée (ex. entier long), un ensemble de valeurs (par exemple, AnnéeEmbauche={1980..2002}, AnnéeEmbauche={1980, 1984, 1995}, AnnéeEmbauche>AnnéeNaissance) ou une valeur obligatoire (ex. "l'attribut *pilote* doit être obligatoirement renseigné")
  - les contraintes *intra-relation* portent sur les valeurs des attributs : unicité de valeur, cardinalité, dépendances entre les valeurs d'attributs différents (ex. "les espèces e3 et e6 ne peuvent cohabiter")
  - les contraintes *inter-relations* sont des dépendances référentielles ou existentielles (ex. "tout vol doit avoir comme commandant de bord une personne référencée dans la table des pilotes")
- les contraintes d'intégrité *dynamiques* sont des propriétés que doit respecter tout changement d'état de la base de données; elles en définissent les séquences possibles de changement d'état. (ex. "le salaire d'un employé ne peut qu'augmenter")

Trois catégories de contraintes d'intégrité structurelles sont particulièrement importantes dans le modèle relationnel : les contraintes d'unicité (chaque table possède une clé d'identification qui en identifie les tuples de manière unique), les contraintes de domaine (les valeurs possibles d'un attribut sont restreintes à un ensemble de valeurs prédéfinies) et les contraintes d'intégrité référentielle (chaque valeur d'une clé étrangère doit exister comme valeur de la clé d'identification dans la table référencée).

### II.6.2. Intégrité référentielle

Comme il a déjà été dit, le mécanisme d'intégrité référentielle impose que chaque valeur d'une clé étrangère existe comme valeur de la clé d'identification dans la table référencée<sup>1</sup>. Tout SGBDR digne de ce nom supporte ce concept fondamental; prenons un exemple pour l'illustrer. Supposons que la normalisation en 3NF de la table ETUDIANT, dans laquelle figure la promotion d'inscription, ait fourni la table de la figure 7-2. On constate qu'aucune valeur de la clé étrangère \_Promo ne viole l'intégrité référentielle. Mais l'insertion d'un tuple tel que "0005, Mader, DESSDC" serait rejetée si la clé primaire de la table PROMOTION ne contient pas la valeur "DESSDC".

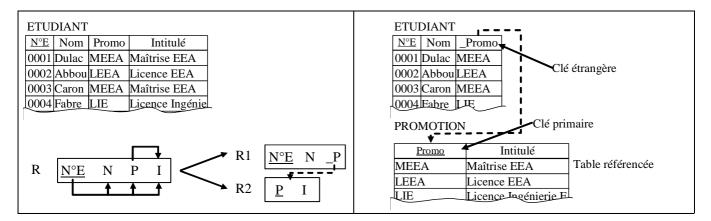


Figure 7-1: Table ETUDIANT en 2NF

Figure 7-2: Forme 3NF et Intégrité référentielle

Le respect de l'intégrité référentielle implique certaines actions. On a vu que le SGBDR vérifiait l'existence d'une valeur de clé étrangère lors de l'insertion d'un nouveau tuple; mais que se passe-t-il si l'on supprime ou si l'on modifie une valeur de la clé primaire dont dépendent d'autres valeurs dans une clé étrangère ? Plusieurs stratégies sont possibles :

- la suppression (ou la mise à jour) interdite : l'opération est tout simplement refusée (ex. la suppression de la ligne "MEEA, Maîtrise EEA" est impossible car des tuples d'ETUDIANT y font référence)
- la suppression (ou la mise à jour) en cascade : dans ce mode, lorsqu'un tuple de la table référencée est supprimé (ou, respectivement, modifié dans ses attributs clés), tous les tuples dépendants sont aussi supprimés (resp. modifiés). Par exemple, la suppression du tuple "MEEA, Maîtrise EEA" entraîne celle des étudiants portant les numéros 0001 et 0003 ; le changement de clé "MEEA" en "MEA" affecte de la même façon les valeurs de la clé étrangère pour ces étudiants.
- la suppression avec initialisation : toutes les clés étrangères égales à la clé primaire supprimée sont mises à la valeur nulle (ex. la suppression du tuple "MEEA, Maîtrise EEA" entraîne la mise à NULL de l'attribut Promo des étudiants portant les numéros 0001 et 0003).

<sup>&</sup>lt;sup>1</sup> Dans les SGBDR, la liaison entre les tables assurée par le mécanisme de clé étrangère se fait par valeur, (comme dans les systèmes de gestion de fichiers); dans les systèmes orientés objets au contraire, cette liaison est réalisée par adresse.

# III. Exploiter les données

# III.1. Bases de l'algèbre relationnelle

#### III.1.1. Définitions préliminaires

Nous donnons ci-dessous une définition formelle de termes déjà rencontrés (cf. exemple figure 8) :

- *Domaine*: Ensemble des valeurs admissibles pour un composant d'une relation. Plusieurs attributs peuvent avoir le même domaine (ex. H\_Dep et H\_Arr: Heure = 00:00..23:59)
- Relation : Sous-ensemble du produit cartésien d'une liste de *n* domaines D<sub>i</sub> : R⊆D<sub>1</sub>×D<sub>2</sub>×...×D<sub>n</sub>, où *n* est appelé *arité* ou *degré* de la relation. En d'autres termes, une relation est une table dans laquelle chaque colonne correspond à un domaine et porte un nom, ce qui rend leur ordre sans importance. L'arité d'une relation est son nombre d'attributs, sa cardinalité est son nombre de tuples.
- Attribut : colonne d'une relation caractérisée par un nom unique et un domaine de définition.
- *Schéma de relation*: nom de la relation, suivi de la liste des attributs avec leurs domaines. Ex. VOL1(N\_Vol: **NumeroVol**, Vil\_Dep: **Ville**, Vil\_Arr: **Ville**, H\_Dep: **Heure**, H\_Arr: **Heure**)
- Base de données relationnelle : Base de données dont le schéma est un ensemble de schémas de relations, où les données sont des tuples de ces relations, et dont la cohérence est définie par un ensemble de contraintes d'intégrité.
- Système de gestion de bases de données relationnelles : logiciel supportant le modèle relationnel et qui peut manipuler les données avec des opérateurs de l'algèbre relationnelle. Ces derniers se divisent en opérateurs ensemblistes et opérateurs relationnels.

# III.1.2. Opérateurs ensemblistes

- Deux relations R et S sont dites *définies sur le même schéma* (ou encore *compatibles avec l'union*) si elles ont même nombre d'attributs (même arité) et que ceux-ci sont définis sur les mêmes domaines (le ième attribut de R et le ième attribut de S ont des domaines identiques, ou sont de même type).
- L'*union* de 2 relations R et S définies sur le même schéma est une relation (T=R∪S ou T=UNION(R,S)) de même schéma contenant l'ensemble des tuples de R et S distincts (ceux qui figurent à la fois dans R et S ne sont conservés qu'une fois).
- L'*intersection* de 2 relations R et S définies sur le même schéma est une relation (T=R∩S ou T=INTERSECT(R,S)) de même schéma et contenant les tuples communs à R et S.
- La *différence* de 2 relations R et S définies sur le même schéma est une relation (T=R-S ou T=R\S ou T=DIFF(R,S)) contenant l'ensemble des tuples de R qui n'appartiennent pas à S.
- Le *produit* (*cartésien*) de 2 relations R et S (par forcément définies sur le même schéma) est une relation (T=R×S ou T=PROD(R,S)) contenant l'ensemble de toutes les combinaisons possibles des tuples de R avec ceux de S.

VOL1	N_Vol	Vil_Dep	Vil_Arr	H_Dep	H_Arr	N_Av
	IT100	Lille	Paris	7:00	7:20	100
	IT101	Paris	Lille	11:00	11:20	100
	IT102	Lyon	Paris	14:00	14:35	101

VOL2	CodeVol	Vil_Dep	Vil_Arr	H_Dep	H_Arr	N_Av
	IT105	Lille	Toulouse	9:00	9:50	101
	IT101	Paris	Lille	11:00	11:20	100

1

IT105

IT101

IT101

VOL3=VOL1\cup VOL2	N_Vol	Vil_Dep	Vil_Arr	H_Dep	H_A	rr N	_Av	
	IT100	Lille	Paris	7:00	7:20	) 1	.00	
	IT101	Paris	Lille	11:00	11:2	0 1	.00	
	IT102	Lyon	Paris	14:00	14:3	5 1	.01	
	IT105	Lille	Toulouse	9:00	9:50	) 1	.01	
VOL3=VOL1∩VOL2	N_Vol	Vil_Dep	Vil_Arr	H_Dep	H_A	rr N	_Av	
	IT101	Paris	Lille	11:00	11:2	0 1	.00	
		•	'		•	•	<u> </u>	
VOL4=VOL1-VOL2	N_Vol	Vil_Dep	Vil_Arr	H_Dep	H_A	rr N	I_A	
	IT100	Lille	Paris	7:00	7:20	) 1	.00	
	IT102	Lyon	Paris	14:00	14:3	5 1	.01	
AVION	N_A	Typ_Av						
	100	A300						
	101	B747						
VOL5=VOL2×AVION	CodeVol	Vil_Dep	Vil_Arr	H_Dep	H_Arr	N_Av	N_A	Typ_A
	IT105	Lille	Toulouse	9:00	9:50	101	100	A300
				0.00	0.70	101	404	

Figure 8: Exemples de résultats avec les opérateurs ensemblistes

Toulouse

Lille

Lille

9:00

11:00

11:00

9:50

11:20

11:20

101

100

100

101

100

101

B747

A300

B747

Lille

**Paris** 

**Paris** 

#### III.1.3. Opérateurs relationnels

- La *projection* (notée  $\pi_M(R)$  ou PROJECT(R,M)) est une opération unaire consistant à supprimer des attributs d'une relation et à éliminer les tuples en doubles dans la nouvelle relation. Formellement, la projection de la relation  $R(A_1,A_2,...,A_n)$  sur un sous-ensemble de ses attributs  $M=\{A_{i1},A_{i2},...,A_{ip}\}$  (avec  $i_j \neq i_k$  et p<n) produit la relation  $R'(A_{i1},A_{i2},...,A_{ip})$  dont les tuples sont obtenus par élimination des valeurs des attributs de R n'appartenant pas à R' et par suppression des tuples en double.
- La *sélection* (ou *restriction*, notée σ<sub>F</sub>(R) ou RESTRICT(R,F)) est une opération unaire qui fournit comme résultat les seuls tuples de la relation R qui satisfont la condition de sélection F. Cette dernière est une formule comportant comme opérandes des attributs de R ou des constantes, liés par des opérateurs de comparaison ("<", ">", "<=", ">=", "<>" ou "=") ou logique (AND, OR et NOT).
- La *jointure* de deux relations R et S d'après le prédicat P (notée R⋈<sub>P</sub>S ou JOIN(R,S,P)) est une combinaison de tous les tuples de R avec ceux de S, qui satisfont le prédicat de jointure P. Ce dernier contient un attribut de R et un attribut de S qui doivent être définis sur le même domaine –, liés par l'un des opérateurs de comparaison. Si cet opérateur est l'égalité, on parle d'*équi-jointure*.
  - *Remarque* : L'opérateur de jointure  $\bowtie_P$  équivaut à une restriction selon P du produit cartésien  $\times$ , c'est-à-dire que  $R\bowtie_P S=\sigma_P(R\times S)$  ; si P est vide, on retrouve ce produit cartésien :  $R\bowtie_{P=\{\}} S=R\times S$ .
- La *division* (ou le quotient, notés  $R \div S$ ) d'une relation R par une relation S n'est possible que si S est une sous-table de R. Si R a pour schéma  $R(T_1,T_2,...,T_j,...,T_m)$  et  $S(T_{p+1},T_{p+2},...,T_m)$ , le résultat est une sous-table de R,  $Q=R \div S$  de schéma  $Q(T_1,T_2,...,T_j,...,T_p)$ , formée de tous les tuples qui, concaténés à chacun des tuples de S, donnent toujours un tuple de R. En d'autre termes, le produit cartésien  $Q \times S$  doit être contenu dans la table R.

1.700

$VOL6=\pi_{Vil\_Arr}(VOL3)$ $Vil\_$	Arr	VOL7=π	Vil_Arr,Vil_De	volts)	Vil	_Arr	V	il_Dep
Pa	is				Li	ille	To	oulouse
Lii	le				Pa	aris		Lille
Toul	ouse							
		T	T = =	T			-	
$VOL8 = \sigma_{Vil\_Arr = "Paris"} (VOL1)$		N_Vol	Vil_D	ep Vi	l_Arr	H_De	p	H_Arr
		IT100	Lille	P	aris	7:00	)	7:20
		IT102	Lyor	n P	aris	14:00	)	14:35
VOL9= $\sigma_{H\_Dep>=11:00 \text{ AND } H\_Arr<15:0}$	(VOL3)	N_Vol	Vil_D	ep Vi	l_Arr	H_De	p	H_Arr
		IT101	Paris	s I	ille	11:00	)	11:20
		IT102	Lyor	n P	aris	14:00	)	14:35
VOL0=VOL2\(\times_{N_AV=N_A}\)AVION	CodeVol	Vil_Dep	Vil_Arr	H_Dep	H_Arr	N_Av	N_A	Typ_Av
	IT105	Lille	Toulouse	9:00	9:50	101	101	B747
	IT101	Paris	Lille	11:00	11:20	100	100	A300

Figure 9 : Exemples de résultats avec les opérateurs relationnels

# III.2. Le langage SQL (Structured Query Language)

Nous ne présentons ici que les fonctionnalités principales de SQL. Pour des informations complémentaires, le lecteur peut se reporter au fichier fourni en annexe ainsi qu'aux ouvrages (principalement les sites internet) cités en bibliographie.

# III.2.1. Introduction

Les langages utilisés dans les bases de données relationnelles se fondent sur l'algèbre relationnelle et/ou le calcul relationnel. Ce dernier est basé sur la logique des prédicats (expressions d'une condition de sélection définie par l'utilisateur). On peut distinguer 3 grandes classes de langages :

- les langages algébriques, basés sur l'algèbre relationnelle de CODD, dans lesquels les requêtes sont exprimées comme l'application des opérateurs relationnels sur des relations. Le langage SQL, standard pour l'interrogation des bases de données, fait partie de cette catégorie.
- les langages basés sur le calcul relationnel de tuples, construits à partir à partir de la logique des prédicats, et dans lesquels les variables manipulées sont des tuples (ex. : QUEL, QUEry Language).
- les langages basés sur le calcul relationnel de domaines, également construit à partir de la logique des prédicats, mais en faisant varier les variables sur les domaines des relations.

Les langages de manipulation de données sont dits déclaratifs, ou assertionnels, c'est-à-dire que l'on spécifie les propriétés des données que l'on manipule et pas - comme dans un langage impératif comment y accéder.

Un langage d'interrogation de bases de données est dit relationnel complet s'il permet au moins l'emploi des trois opérateurs ensemblistes (union, différence et produit cartésien) et des deux opérateurs relationnels de projection et sélection. Plus généralement, outre la recherche ou sélection de données, les langages de manipulation de données permettent souvent :

- la création de table, l'insertion, la suppression et la modification de tuples vérifiant certains critères ;
- de réaliser des calculs sur des agrégats (ex. somme, minimum ou moyenne de valeurs d'un attribut) ;

- de présenter les données sous certains formats (ex. séquences de tris) ;
- de gérer les autorisations d'accès pour assurer la protection de la base ;
- de garantir la sécurité des données en prenant en compte l'environnement multi-utilisateurs.

SQL est un langage normalisé (dernière version : SQL:2011) permettant :

- l'interrogation de la base (clause SELECT)
- la manipulation de données (UPDATE, INSERT, DELETE)
- la définition des données (ALTER, CREATE, DROP)
- le contrôle des données (GRANT, REVOKE, COMMIT, ROLLBACK)

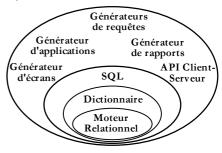


Figure 10: SQL au sein d'un SGBD

Tout SGBD contient un *dictionnaire* (figure 10) qui contient à tout moment le descriptif complet des données, sous la forme d'un ensemble de tables comprenant les bases de données présentes, les tables et leurs attributs, les clés candidates, primaires et étrangères, les différentes contraintes et les vues créées sur les tables. SQL utilise ce dictionnaire lors de l'exécution de requêtes pour vérifier les contraintes, optimiser les requêtes et assurer le contrôle des accès.

### III.2.2. Interroger une base de données

#### III.2.2.1. Introduction

La commande **SELECT** constitue, à elle seule, le langage d'interrogation d'une base. Elle permet :

- de sélectionner certaines colonnes d'une table (opération de *projection*) ;
- de sélectionner certaines lignes d'une table en fonction de leur contenu (restriction) ;
- de combiner des informations venant de plusieurs tables (jointure, union, intersection, différence);
- de combiner ces différentes opérations

Une *interrogation*, ou *requête de sélection*, est une combinaison d'opérations portant sur des tables et dont le résultat est lui-même une table, mais éphémère ou *dynamique* (car elle n'existe que le temps de la requête).

Dans ce qui suit, nous utiliserons les conventions typographiques suivantes :

- en MAJUCULES les commandes ou opérateurs qu'il faut recopier tels quels (ex. SELECT)
- en italique les paramètres devant être remplacés par une valeur appropriée (ex. table, alias)
- en souligné la valeur par défaut (ex. {ASC | DESC})
- des crochets [...] encadrent une valeur optionnelle (ex. [DISTINCT], [AS alias])
- des accolades {...} encadrent des valeurs (séparées par | ) dont l'une doit être saisie (ex. {ON | OFF})
- des points de suspension ... indiquent que les valeurs précédentes peuvent être répétées plusieurs fois (ex. table, ... peut prendre comme valeur table1, table2, table3)
- les signes de ponctuation (parenthèses, virgules et points-virgules) doivent être saisis comme présentés. En particulier, ne pas oublier le **point-virgule obligatoire** à la fin de chaque requête.

Par ailleurs, on désigne par :

- alias un synonyme d'un nom de table, de colonne, ou d'expression calculée
- *condition* une expression prenant la valeur vrai ou faux
- *sous-interrogation* (ou *sous-requête*) une expression de requête (SELECT) figurant dans une clause WHERE d'une requête principale
- expr une colonne ou un attribut calculé par une expression
- *num* un numéro de colonne

Enfin, dans ce qui suit, nous illustrerons les requêtes sur une base formée des relations suivantes :

Employes(<u>num\_emp</u>, nom, fonction, \_superieur, date\_embauche, salaire, comm,
\_num\_dep)

EMPLOYES	num_emp	nom	fonction	_superieur	date_embauche	salaire	comm	_num_dep
	7369	Coquillet	Technicien	7902	17/12/80	800		20
	7499	Parent	Commercial	7698	20/02/81	1600	300	30
	7521	Henry	Commercial	7698	22/02/81	1250	500	30
	7566	Dumoulin	Directeur	7839	02/04/81	2975		20
	7654	Ferron	Commercial	7698	28/09/81	1250	1400	30
	7698	Capon	Directeur	7839	01/05/81	2850		30
	7782	Martin	Directeur	7839	09/06/81	2450		10
	7788	Colin	Analyste	7566	19/04/87	3000		20
	7839	Patton	Président		17/11/81	5000		10
	7844	Benami	Commercial	7698	08/09/81	1500	0	30
	7876	Calamon	Technicien	7788	23/05/87	1100		20
	7900	James	Technicien	7698	03/12/81	950		30
	7902	Henry	Analyste	7566	03/12/81	3000		20
	7934	Tozzi	Technicien	7782	23/01/82	1300		10

#### Departements(num\_dep, nom, ville)

DEPARTEMENTS	num_dep	nom	ville
	10	Comptabilité	Paris
	20	Recherche	Lille
	30	Ventes	Marseille
	40	Opérations	Lyon

### III.2.2.2. Syntaxe de base

La syntaxe de base de la commande SELECT est la suivante :

SELECT	attributs	Correspond à l'opérateur de projection $\pi_{attributs}(tables)$
FROM	tables	attributs (
WHERE	prédicats;	Correspond aux opérateurs de jointure $\bowtie_{prédicat}$ et/ou de sélection $\sigma_{prédicat}$

Les attributs sont les colonnes que l'on souhaite voir apparaître dans la réponse. Si l'on souhaite toutes les colonnes, il faut utiliser le symbole \*.

Ex.

```
SELECT * FROM employes; Affiche la table employes avec toutes ses colonnes

SELECT nom, fonction FROM employes; Affiche le nom et la fonction de tous les employés
```

Il est possible de faire précéder les noms des attributs de la table où ils figurent. Cela est obligatoire si l'on extraie les données de plusieurs tables et que deux attributs sélectionnés portent le même nom :

```
SELECT employes.nom, departements.nom FROM employes, departements;
```

Il est aussi possible de renommer une colonne ou une table par un *alias*, ce qui est utile lorsqu'on veut donner un nom plus « parlant » ou plus court pour faciliter sa désignation ultérieurement dans la requête. Pour renommer une colonne, on utilise la syntaxe Coll AS 'Nouveau nom' dans le SELECT (les guillemets ne sont obligatoires que si l'alias comporte des espaces ou des caractères spéciaux). Pour renommer une table, il suffit de faire suivre son nom par son alias dans la clause FROM :

```
SELECT emp.nom, emp.salaire AS 'salaire mensuel' FROM employes emp;
```

Ceci est particulièrement utile lorsque l'on définit un *attribut calculé* à partir des attributs de tables. Il est en effet possible de faire figurer comme résultat d'un SELECT une expression composée d'opérateurs, de fonctions prédéfinies (*cf.* liste en annexe), de variables et de constantes :

```
SELECT nom, salaire+comm AS 'salaire total' FROM employes;
```

*La clause WHERE* permet de spécifier quelles sont les lignes à sélectionner. Le prédicat de sélection, formé d'une expression comportant des opérandes liés par des opérateurs, sera évalué pour chaque ligne de la table, et seules les lignes pour lesquelles il est vrai seront retenues

Les opérandes figurant dans le prédicat peuvent être des noms de colonnes, ou des constantes de type :

- nombres : peuvent inclure un signe, un point décimal et une puissance de dix (ex. -1.2E-5)
- chaînes : chaînes de caractères entre apostrophes (Attention : 'Martin' ≠ 'MARTIN')
- dates : chaînes de caractères entre apostrophes dans un format spécial. Pour s'affranchir des problèmes inhérents aux incompatibilités dans les différentes langues, il est conseillé d'utiliser le format suivant : 'aaaa-mm-jj' (ex. {d '2001-10-31'})
- la valeur NULL (valeur non définie), que l'on doit tester avec l'opérateur IS, et pas = (cf. ci-dessous).

Les opérateurs figurant dans le prédicat peuvent être :

- les opérateurs de comparaison traditionnels (= (égal), <> (différent de), <, <=, >, >=)
- les opérateurs spéciaux
  - BETWEEN ... AND (valeur comprise entre 2 bornes): expr1 BETWEEN expr2 AND expr3
  - IN (valeur comprise dans une liste): expr1 IN (expr2, expr3, ...)
  - LIKE (chaîne semblable à une chaîne générique) : expr1 LIKE chaine

    La chaîne générique peut comporter les caractères jokers '\_' (remplace 1 seul caractère quelconque) et '%' (remplace une chaîne de caractères quelconque, y compris de longueur nulle)
- les opérateurs logiques AND, OR et NOT (inversion logique) pour combiner plusieurs prédicats. Des parenthèses peuvent être utilisées pour imposer une priorité dans l'évaluation du prédicat (par défaut, l'opérateur AND est prioritaire par rapport à OR).

### Exemples.

- Employés dont la commission est supérieure au salaire SELECT nom, salaire, comm FROM employes WHERE comm > salaire;
- Employés gagnant entre 1500 et 2850€ SELECT nom, salaire FROM employes WHERE salaire BETWEEN 1500 AND 2850;
- Employés commerciaux ou analystes

```
SELECT num_emp, nom, fonction FROM employes
WHERE fonction IN ('Commercial', 'Analyste');
```

- Employés dont le nom commence par M

SELECT nom FROM employes WHERE nom LIKE 'M%';

- Employés du département 30 ayant un salaire supérieure à 2500€ SELECT nom FROM employes WHERE num dep=30 AND salaire>2500;

- Employés directeurs ou commerciaux travaillant dans le département 10 SELECT nom, fonction FROM employes WHERE (fonction='Directeur' OR fonction ='Commercial') AND \_num\_dep=10;

- Employés percevant une commission
SELECT nom, salaire, comm FROM employes WHERE comm IS NOT NULL;

#### III.2.2.3. Les jointures

La jointure est une opération permettant de combiner des informations issues de plusieurs tables. Elle se formule simplement en spécifiant, dans la clause FROM, le nom des tables concernées et, dans la clause WHERE, les conditions qui vont permettre de réaliser la jointure (en effet, si l'on ne précise pas de condition de sélection, on obtient le produit cartésien des tables présentes derrière le FROM, ce qui n'est en général pas souhaité).

Il existe plusieurs types de jointures (cf. figure 11) :

- *equi-jointure* (ou *jointure naturelle*, ou *jointure interne*): permet de relier deux colonnes appartenant à deux tables différentes mais ayant le même "sens" et venant vraisemblablement d'une relation 1-N lors de la conception. Les tables sont reliées par une relation d'égalité entre leur attribut commun ou, à partir de SQL2, avec la clause INNER JOIN.

```
Ex. Donner le nom de chaque employé et la ville où il/elle travaille
   SELECT employes.nom, Ville FROM employes, departements
   WHERE employes._num_dep=departements.num_dep;

ou
   SELECT employes.nom, departements.ville FROM employes
   INNER JOIN departements ON employes._num_dep = departements.num_dep;
```

- *auto-jointure* : cette jointure d'une table à elle-même permet de relier des informations venant d'une ligne d'une table avec des informations venant d'une autre ligne de la même table. Dans ce cas, il faut renommer au moins l'une des deux occurrences de la table pour pouvoir préfixer sans ambiguïté chaque nom de colonne.

```
Ex. Donner pour chaque employé le nom de son supérieur hiérarchique

SELECT employes.nom, superieurs.nom FROM employes, employes AS superieurs
WHERE employes._superieur=superieurs.num_emp;

ou

SELECT employes.nom, superieurs.nom FROM employes
INNER JOIN employes AS superieurs
ON employes._superieur=superieurs.num_emp;
```

*θ-jointure* : si le critère d'égalité correspond à la jointure la plus naturelle, les autres opérateurs de comparaison sont également utilisables dans le prédicat de jointure. Néanmoins, cette possibilité doit être utilisée avec précaution car elle peut entraîner une explosion combinatoire (on rappelle qu'une jointure ne constitue qu'une restriction du produit cartésien de deux relations ou plus).

```
Ex. Quels sont les employés gagnant plus que Martin ?
SELECT el.nom, el.salaire, el.fonction FROM employes AS el, employes AS e2
WHERE el.salaire>e2.salaire AND e2.nom='Martin';
```

*jointure externe*: lorsqu'une ligne d'une table figurant dans une jointure n'a pas de correspondant dans les autres tables, elle ne satisfait pas au critère d'équi-jointure et ne figure donc pas dans le résultat de la requête. Une jointure externe est une jointure qui favorise l'une des tables en affichant toutes ses lignes, qu'il y ait ou non correspondance avec l'autre table de jointure. Les colonnes pour lesquelles il n'y a pas de correspondance sont remplies avec la valeur NULL. Pour définir une telle jointure, on utilise les clauses LEFT OUTER JOIN (*jointure externe gauche*) et RIGHT OUTER JOIN (*jointure externe droite*).

```
Ex. Le département de Lyon n'apparaissait pas dans l'exemple de l'équi-jointure, mais figurera ici : 
SELECT employes.nom, departements.ville FROM employes 
RIGHT JOIN departements ON employes._num_dep = departements.num_dep;
```

Ex. Le Président Patton, sans supérieur hiérarchique, n'apparaissait pas dans l'exemple de l'autojointure, mais figurera ici (avec NULL comme nom de supérieur):
SELECT employes.nom, superieurs.nom FROM employes
LEFT JOIN employes AS superieurs ON employes.\_\_superieur=superieurs.num\_emp;

#### Ex. Retrouver les départements n'ayant aucun employé :

SELECT departements.num\_dep, employes.nom FROM employes
RIGHT JOIN departements ON employes.\_num\_dep = departements.num\_dep
WHERE employes.nom IS NULL;

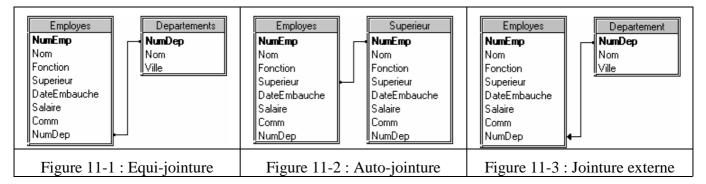


Figure 11 : Les différents types de jointures

#### III.2.2.4. Fonctions de groupes

Dans les exemples précédents, chaque ligne résultat d'un SELECT était calculée sur les valeurs d'une seule ligne de la table consultée. Il existe un autre type de SELECT qui permet d'effectuer des calculs sur l'ensemble des valeurs d'une colonne, au moyen de l'une des *fonctions de groupe* suivantes (toutes portent sur une expression, qui peut-être un attribut d'une table ou un attribut calculé) :

SUM(expr)AVG(expr)Somme des valeursMoyenne des valeurs

- COUNT([DISTINCT] expr) Nombre de valeurs (différentes si DISTINCT est présent)

COUNT(\*)
 MIN(expr) ou MAX(expr)
 VARIANCE(expr) ou STDDEV(expr)
 Compte toutes les lignes de la table
 Minimum ou maximum des valeurs
 Variance ou écart-type des valeurs

Ex.: Donner le total des salaires des employés travaillant dans le département 10: SELECT SUM(salaire) AS som\_salaires FROM employes WHERE \_num\_dep=10;

Calcul de résultats sur plusieurs groupes. Il est possible de subdiviser la table en *groupes*, chaque groupe étant l'ensemble des lignes ayant une valeur commune pour les expressions spécifiées. C'est la clause GROUP BY qui permet de découper la table en plusieurs groupes :

### GROUP BY expr1, expr2, ...

Si l'on regroupe suivant une seule expression, ceci définit les groupes comme les ensembles de lignes pour lesquelles cette expression prend la même valeur. Si plusieurs expressions sont présentes, le groupement va s'effectuer d'abord sur la première, puis sur la seconde, et ainsi de suite : parmi toutes les lignes pour lesquelles *expr1* prend la même valeur, on regroupe celles ayant *expr2* identique, etc. Un SELECT de groupe avec une clause GROUP BY donnera une ligne résultat pour chaque groupe.

Ex.: Donner le total des salaires des employés pour chaque département :
 SELECT \_num\_dep, SUM(salaire) AS som\_salaires FROM employes GROUP BY \_num\_dep;

**Sélection des groupes**. De même que la clause WHERE permet de sélectionner certaines lignes, il est possible de ne retenir, dans un SELECT comportant une fonction de groupe, que les lignes répondant à un critère donné par la clause HAVING. Cette clause se place après la clause GROUP BY et son prédicat suit les mêmes règles de syntaxe que celui de la clause WHERE, à la différence près qu'il ne

peut porter que sur des caractéristiques du groupe (fonction de groupe ou expression figurant dans la clause GROUP BY).

Ex.: Donner la liste des salaires moyens par fonction pour les groupes ayant plus de 2 employés: SELECT fonction, COUNT(\*) AS nb\_employes, AVG(salaire) AS moy\_salaires FROM employes GROUP BY fonction HAVING COUNT(\*)>2;

# Remarques importantes:

- Dans la liste des colonnes résultat d'un SELECT comportant une fonction de groupe, ne peuvent figurer que des caractéristiques de groupe, c'est-à-dire soit des fonctions de groupe, soit des expressions figurant dans la clause GROUP BY. En effet, de manière générale, lorsqu'un attribut est sélectionné dans une clause SELECT, le résultat peut comporter de zéro à n valeurs ; cela pourrait provoquer des conflits si l'on utilisait conjointement des fonctions statistiques qui, elles, ne retournent qu'une seule valeur.
- Un SELECT de groupe peut contenir à la fois les clauses WHERE et HAVING. La première sera d'abord appliquée pour sélectionner les lignes, puis les fonctions de groupe seront évaluées, et les groupes ainsi constitués seront sélectionnés suivant le prédicat de la clause HAVING.

Ex. : Pour les départements comportant au moins 2 employés techniciens ou commerciaux, donner le nombre de ces employés par département :

```
SELECT _num_dep, COUNT(*) AS nb_techn_ou_comm FROM employes
WHERE fonction in('Technicien','Commercial')
GROUP BY _num_dep HAVING COUNT(*)>=2;
```

- Un SELECT de groupe peut être utilisé dans une sous-interrogation ; inversement, une clause HAVING peut comporter une sous-interrogation.

#### III.2.2.5. Sous-interrogations

Une caractéristique puissante de SQL est la possibilité qu'un critère de recherche employé dans une clause WHERE (expression à droite d'un opérateur de comparaison) soit lui-même le résultat d'un SELECT; c'est ce que l'on appelle une *sous-interrogation* ou un *SELECT imbriqué*. Cela permet de réaliser des interrogations complexes qui nécessiteraient sinon plusieurs interrogations avec stockage des résultats intermédiaires.

Un SELECT peut retourner de zéro à n lignes comme résultat. On a donc les cas suivants :

- Une sous-interrogation ne retournant aucune ligne se termine avec un code d'erreur, à moins d'utiliser l'opérateur EXISTS qui retourne *faux* dans ce cas, *vrai* si la sous-interrogation retourne au moins une ligne. Cet opérateur permet d'empêcher l'exécution de l'interrogation principale si la sous-interrogation ne retourne aucun résultat, mais s'emploie surtout avec les sous-interrogations synchronisées (*cf.* plus loin).

```
Ex.: Donner la liste des noms et salaires des employés si un des salaires est inférieur à 1000 :
SELECT nom, salaire FROM employes
WHERE EXISTS(SELECT * FROM employes WHERE salaire<1000);</p>
```

- Si le résultat d'une sous-interrogation ne comporte qu'une seule ligne, il peut être utilisé directement avec les opérateurs de comparaison classiques.

```
Ex.: Donner le nom des employés exerçant la même fonction que Martin:
    SELECT nom FROM employes
    WHERE fonction = (SELECT fonction FROM employes WHERE nom='Martin');
```

- Une sous-interrogation peut retourner plusieurs lignes à condition que l'opérateur de comparaison admette à sa droite un ensemble de valeurs. Les opérateurs permettant de comparer une valeur à un ensemble de valeurs sont :

IN	Retourne vrai si la valeur est égale à l'une des valeurs retournées par la sous-interrogation.
ANY	Retourne vrai si la comparaison est vraie pour l'une au moins des valeurs retournées par la
	sous-interrogation. Peut suivre l'un des opérateurs =,<>,>,>=,<, ou <=.
ALL	Retourne vrai si la comparaison est vraie pour toutes les valeurs retournées par la sous-
	interrogation. Peut suivre l'un des opérateurs =,<>,>,>=,<, ou <=.

```
Ex.: Donner la liste des employés gagnant plus que tous ceux du département 30:
SELECT nom, salaire FROM employes
WHERE salaire > ALL(SELECT salaire FROM employes WHERE _num_dep=30);
```

Sous-interrogation synchronisée avec l'interrogation principale. Dans les exemples précédents, la sous-interrogation était évaluée d'abord, puis son résultat était utilisé pour exécuter l'interrogation principale. SQL sait également traiter une sous-interrogation faisant référence à une colonne de la table de l'interrogation principale. Dans ce cas, le traitement est plus complexe car il faut évaluer la sous-interrogation pour chaque ligne de l'interrogation principale.

```
Ex.: Donner la liste des employés ne travaillant pas dans le même département que leur supérieur :
    SELECT nom FROM employes e
    WHERE _num_dep<>(SELECT _num_dep FROM employes WHERE
e._superieur=num_emp)
```

Il a fallu ici renommer la table Employes de l'interrogation principale pour pouvoir la référencer sans ambiguïté dans la sous-interrogation. La dernière ligne est utile car le président ne possède pas de supérieur (valeur NULL) et la sous-interrogation ne retourne alors aucune valeur.

```
Ex.: Donner les employés des départements qui n'ont pas embauché depuis le début de l'année 1982 :
    SELECT * FROM employes e
    WHERE NOT EXISTS(SELECT * FROM employes WHERE
    date_embauche>=to_date('01/01/1982','DD-MM-YYYY') AND _num_dep=e._num_dep);
```

# III.2.2.6. Récapitulatif : syntaxe étendue

AND \_superieur IS NOT NULL;

La syntaxe étendue de l'instruction SELECT est la suivante :

```
SELECT [DISTINCT] {* | expr [AS alias], ... }
FROM table [alias], ...
[WHERE { conditions | sous conditions} ]
[GROUP BY expr, ...] [HAVING conditions]
[ORDER BY {expr | num}{ASC | DESC}, ...];
```

Clause	Précise	Notes
SELECT	Colonnes qui vont apparaître dans la réponse	* = toutes les colonnes
	(DISTINCT permet d'éliminer les tuples en double)	AS pour renommer une expression
FROM	Table(s) intervenant dans l'interrogation	Alias surtout utile dans les jointures
WHERE	Conditions à appliquer sur les lignes. Peut inclure :	Jointures aussi définies par :
	- comparateurs : =, >, <, >=, <=,<>	- INNER JOIN (équi- et auto-jointure)
	- opérateurs logiques : AND, OR, NOT	- LEFT OUTER JOIN et RIGHT
	- prédicats : IN, LIKE, ALL, SOME, ANY, EXISTS,	OUTER JOIN (jointures externes)
GROUP BY	Colonne(s) de regroupement	
HAVING	Condition(s) associée(s) à un regroupement	
ORDER BY	Ordre dans lequel vont apparaître les lignes de la réponse	DESC = ordre descendant

### III.2.3. Modifier une base de données

### III.2.3.1. Manipulation de données (LMD)

Le langage de manipulation de données permet de modifier les informations contenues dans la base de données. Les modifications ne peuvent se faire que sur une seule table à la fois, et l'unité manipulée est la ligne. Il existe une commande SQL correspondant à chaque type de modification de données : ajout, modification et suppression.

Remarques importantes: Les opérations de mise à jour sont susceptibles d'être rejetées par le moteur SQL, notamment si elles violent des contraintes d'intégrité des données. Par ailleurs, ces commandes doivent être utilisées avec précaution car elles modifient les données de manière définitive (il est impossible de revenir sur un ordre de mise à jour si l'on s'est trompé).

La commande INSERT permet d'insérer une ligne dans une table existante en spécifiant les valeurs à insérer. On peut spécifier explicitement les colonnes pour lesquelles on va fournir des valeurs ; si elle est omise, la liste des colonnes sera par défaut celle de la table dans l'ordre donné lors de sa création.

```
INSERT INTO nom_table (nom_col1, nom_col2,...) VALUES (val_col1, val_col2,...)
Ex.: Insérer un tuple dans la table Employes:
   INSERT INTO employes(nom, fonction, salaire, comm)
   VALUES ('Copin', 'Commercial', 1500, 150)
```

Il est possible d'insérer dans une table les lignes provenant d'une requête d'interrogation SELECT qui peut contenir n'importe quelle clause sauf un ORDER BY (ce classement des lignes serait contraire à l'esprit du relationnel) :

```
INSERT INTO nom_table (nom_col1, nom_col2, ...) SELECT...
```

La commande UPDATE permet de modifier les valeurs d'une ou plusieurs colonnes, dans une ou plusieurs lignes existantes d'une table :

```
UPDATE nom_table
SET nom_col1 = expr1, nom_col2 = expr2, ...
WHERE prédicat;
```

Les valeurs des colonnes *nom\_col1*, *nom\_col2*, ... sont modifiées dans toutes les lignes satisfaisant au prédicat ; celui-ci peut contenir une sous-requête afin de filtrer de manière plus complète. En l'absence de clause WHERE, toutes les lignes sont mises à jour.

Les expression de mise à jour *expr1*, *expr2*, ... peuvent contenir des constantes (numériques, dates, chaînes), des opérateurs et fonctions, et peuvent même faire référence aux anciennes valeurs de la ligne.

```
Ex.: Augmenter de 10% les analystes:

UPDATE employes SET salaire=salaire*1.1 WHERE fonction='Analyste'
```

#### La commande DELETE permet de supprimer des lignes d'une table :

```
DELETE FROM nom_table WHERE prédicat;
```

Toutes les lignes pour lesquelles le prédicat est vrai sont supprimées. En l'absence de clause WHERE, la table est vidée de toutes ses lignes.

```
III.2.3.2. Description des données (LDD)
```

*Note* : Les notions évoquées ici ne sont qu'un survol très rapide du langage de description des données. Pour un exposé complet des commandes SQL de création de schéma, le lecteur peut se reporter au site de Frédéric Brouard (*cf.* bibliographie).

La commande CREATE TABLE permet de définir une table, avec ses colonnes et ses contraintes :

```
CREATE TABLE nom_table {colonne|contrainte}, {colonne|contrainte_tbl}, ...
```

où *colonne* définit à la fois le nom de la colonne, mais aussi son type, sa valeur par défaut et ses éventuelles contraintes de colonne (la colonne peut en effet accepter ou non les valeurs nulles, certaines valeurs de validation, les doublons, ou bien être une clé primaire ou étrangère) :

et où les contraintes de table permettent de définir une clé multi-colonnes ainsi que des contraintes portant sur plusieurs colonnes (unicité globale, validation multi-attributs ou intégrité référentielle) :

```
contrainte_tbl:: CONSTRAINT nom_contrainte
{PRIMARY KEY (liste_cols) | UNIQUE | CHECK (prédicat_tbl) | FOREIGN KEY
(liste_cols) REFERENCES table(liste_cols) spécif_référence}
```

Ex. : Si l'on souhaite imposer les contraintes suivantes à la table Employés :

- les valeurs de département doivent appartenir à l'intervalle 10..100
- les fonctions sont forcément 'Directeur', 'Analyste', 'Technicien', 'Commercial' ou 'President'
- tout employé embauché après 1986 doit gagner plus de 1000€

#### sa définition serait :

```
CREATE TABLE employes (
    num_emp
                  SMALLINT
                             NOT NULL PRIMARY KEY,
    nom
                  VARCHAR(9),
                             CHECK (fonction IN ('Directeur', 'Analyste',
    fonction
                  CHAR (10)
                                  'Technicien', 'Commercial', 'President')),
    _superieur
                  SMALLINT
                             FOREIGN KEY REFERENCES employes (num_emp),
    Date embauche DATE,
    salaire
                 DECIMAL(7,2),
                  DECIMAL(7,2),
    COMM
                  SMALLINT CHECK (_num_dep BETWEEN 10 AND 100),
    num dep
    CONSTRAINT ChkSal CHECK (YEAR(date_embauche) <= 1986 OR salaire > 1000) );
```

La commande ALTER TABLE permet de modifier la définition d'une table en y ajoutant ou en supprimant une colonne ou une contrainte (mais elle ne permet pas de changer le nom ou le type d'une colonne, ni d'ajouter une contrainte de ligne [NOT] NULL) :

```
ALTER TABLE nom_table {
   ADD definition_colonne |
   ADD CONSTRAINT definition_contrainte |
   ALTER nom_colonne {SET DEFAULT valeur_def | DROP DEFAULT} |
   DROP nom_colonne [CASCADE | RESTRICT] |
   DROP CONSTRAINT nom_contrainte [CASCADE | RESTRICT] };
```

L'option CASCADE / RESTRICT permet de gérer l'intégrité référentielle de la colonne ou la contrainte.

Ex.: Modifier la définition de la table Employés pour que le salaire total dépasse forcément 1000€:

```
ALTER TABLE employes ADD CONSTRAINT ChkSalTot CHECK (salaire+comm > 1000)
```

La commande DROP TABLE permet de supprimer la définition d'une table et, dans le même temps, de tout son contenu et des droits d'accès des utilisateurs à la table (à utiliser avec précaution, donc !) :

```
DROP TABLE nom_table
```

### III.2.3.3. Contrôle des données (LCD)

La *protection des données* consiste à identifier les utilisateurs et gérer les autorisations d'accès. Pour cela, une mesure fondamentale est de ne fournir aux utilisateurs qu'un accès aux tables ou aux parties de tables nécessaires à leur travail, ce que l'on appelle des *vues*. Grâce à elles, chaque utilisateur pourra avoir sa vision propre des données. Une vue est définie en SQL grâce à la commande CREATE VIEW comme résultat d'une requête d'interrogation SELECT:

```
CREATE VIEW nom_vue AS SELECT ...
```

Ex. : Créer une vue constituant une restriction de la table Employés aux nom et salaire des employés du département 10 :

```
CREATE VIEW emp10 AS SELECT nom, salaire FROM employes WHERE _num_dep = 10;
```

Il n'y a pas de duplication des informations, mais stockage de la définition de la vue. Une fois créée, la vue peut être interrogée exactement comme une table. Les utilisateurs pourront consulter la base à travers elle, c'est-à-dire manipuler la table résultat du SELECT comme s'il s'agissait d'une table réelle. En revanche, il existe deux restrictions à la manipulation d'une vue par un INSERT ou un UPDATE :

- le SELECT définissant la vue ne doit pas comporter de jointure ;
- les colonnes résultats du SELECT doivent être des colonnes réelles et non pas des expressions.

Ex.: Augmentation de 10% des salaires du département 10 à travers la vue Emp10 : UPDATE emp10 SET salaire=salaire\*1.1;

Une vue peut être supprimée ou renommée par les commandes :

```
DROP VIEW nom_vue ou RENAME ancien_nom TO nouveau_nom
```

Une protection efficace des données nécessite en outre d'autoriser ou d'interdire certaines opérations, sur les tables ou les vues, aux différentes catégories d'utilisateurs. Les commandes correspondantes sont :

```
GRANT type_privilege1, type_privilege2,... ON {table|vue|*} TO utilisateur; REVOKE type_privilege1, type_privilege2,... ON {table|vue|*} FROM utilisateur;
```

Les types de privilèges correspondent aux commandes SQL (SELECT pour la possibilité d'interroger, UPDATE pour celle de mise à jour, etc.) et les utilisateurs concernés sont désignés par leur identifiant de connexion au serveur, ou par le mot-clé PUBLIC pour désigner tous les utilisateurs.

Ex. : Autoriser la suppression de la vue Emp10 au seul représentant du personnel identifié par ID7788 : GRANT DELETE ON emp10 TO ID7788;

Gestion des transactions. Une transaction est un ensemble de modifications de la base qui forment un tout indivisible, qu'il faut effectuer entièrement ou pas du tout, sous peine de laisser la base dans un état incohérent. SQL permet aux utilisateurs de gérer leurs transactions :

- la commande COMMIT permet de valider une transaction. Les modifications deviennent définitives et visibles à tous les utilisateurs ;
- la commande ROLLBACK permet à tout moment d'annuler la transaction en cours. Toutes les modifications effectuées depuis le début de la transaction sont alors défaites.

Pour assurer ainsi l'intégrité de la base en cas d'interruption anormale d'une tâche utilisateur, les SGBD dits *transactionnels* utilisent un mécanisme de verrouillage qui empêche deux utilisateurs d'effectuer des transactions incompatibles.

# - Bibliographie -

- A. Meier (2002). *Introduction pratique aux bases de données relationnelles*. Springer-Verlag France, Collection Iris (B.U. 005.756 MEI).
- S. Maouche (2000). *Bases de données et Systèmes de gestion de bases de données*. Cours universitaire (non publié).
- A. Abdellatif, M. Limame, A. Zeroual (1998). *Oracle 7: langage architecture administration*. Eyrolles, Paris.
- J. Akoka, I. Comyn-Wattiau (2001). *Conception des bases de données relationnelles, en pratique*. Vuibert, Paris, Collection Informatique (B.U. 005.756 AKO).
- Sites web
  - Introduction aux modèles EA et relationnel : www.iutc3.unicaen.fr/~moranb/cours/acsi/menu.htm
  - Bases de données, SGBD: www-lsr.imag.fr/Les.Personnes/Herve.Martin/HTML/FenetrePrincipale.htm
  - SGBD et SQL : wwwdi.supelec.fr/~yb/poly\_bd/node1.html
  - Algèbre relationnelle, SQL (exo en ligne): tlouahlia.free.fr/cours/tmp/SQL/ar&sql.htm
  - SQL (apprentissage interactif): www.marc-grange.net/SQL.htm
  - Site de F. Brouard sur SQL (très complet) : sqlpro.developpez.com/indexSQL.html